资金数据清洗工具

使用说明（按程序执行步骤）

版本：V1.9

适用环境：Windows 10 内网（离线）

开发环境：macOS · Python 3.12 目标版 · PySide6 · pandas

济宁经侦-田成 57018 © 2026

说明：本手册按程序实际执行的步骤顺序编写，用于了解数据从输入到输出的完整处理链路。*V1.9* 将资金交易流水调整为 *8* 步定向处理：清空前后空白、全字段去重、双空行删除、账户键及身份信息补全、金额数值化、收付标志标准化、六字段最终去重。账户信息表及其他非流水表的原有清洗和输出逻辑保持不变。

目 录

一、项目概述

二、界面使用流程（用户操作步骤）

三、程序执行流程总览

四、程序执行步骤详解（核心）

五、数据格式与关键约定

六、关键技术与已解决问题

七、实际测试结果示例

八、基于执行步骤的优化建议

一、项目概述

资金数据清洗工具是一款内网离线桌面应用，批量处理银行资金流水 ZIP 数据包，自动完成解压、合并、清洗、主数据补全、字段标准化、去重和分表，输出标准化 XLSX。V1.9 对资金交易流水执行 8 步定向处理，并以六字段完成最终去重。

技术栈：Python 3.12（Win10 目标版）· PySide6（GUI）· pandas + openpyxl（数据处理）· chardet（编码检测）· PyInstaller（打包为单 EXE）

测试：**pytest（116 个测试用例，覆盖各处理模块与端到端流程）**

1.1 模块结构

目录/文件	职责
main.py	PySide6 GUI 入口，界面构建、文件选择、进度展示、子线程调度
build.spec	PyInstaller 打包配置
resources/icon.ico	程序图标
core/extractor.py	解压：从银行 ZIP 文件名解析银行名 + CSV 类型
core/format_adapter.py	V1.7 新增：识别“逐卡”新版反馈包，用文件名卡号补全为空的交易卡号
core/merger.py	合并：按类型合并同类 CSV，新增“银行来源”列
core/converter.py	CSV→XLSX 转换；长数字列强制文本；汇总超限自动分片
core/deduper.py	**去重：流水先全字段去重，最终按 6 字段**
core/cleaner.py	**清洗：删除交易时间和交易金额同时为空的行；金额数值化与收付标志标准化**
core/completer.py	补全：从账户表匹配户名 + 证件号，卡号↔账号双向互填
core/splitter.py	分表：按 银行_户名 拆分为独立 XLSX
core/pipeline.py	流程编排：串联全部步骤，提供进度/错误回调
utils/config.py	常量、CSV 类型关键词、parse_bank_zip_name(_v2)
utils/encoding.py	chardet 编码检测（GB18030 低置信度直接信任）
utils/csv_utils.py	分隔符检测 + read_csv_auto（多编码/引擎回退）
utils/logger.py	INFO/WARN/ERROR 三级日志

二、界面使用流程（用户操作步骤）

用户在界面按以下顺序操作，程序在后台子线程执行数据处理，界面实时显示进度。新版“逐卡”反馈包仍可自动识别，无需手动切换；V1.9 的流水处理规则对旧版和新版包均生效。

步骤	操作	说明
1	启动程序	双击“资金数据清洗工具.exe”（或 python main.py 源码运行）
2	选择 ZIP 文件	点击“选择 ZIP 文件”，可多选；通常是案件包（顶层 ZIP），新版/旧版均可
3	选择输出目录	默认指向桌面，可点击“选择文件夹”修改
4	设置选项	【保留中间文件】【遇错停止】两个复选框
5	点击“开始处理”	程序在子线程执行完整流程，进度条与状态栏显示当前步骤
6	查看进度/结果	完成后弹窗提示；输出目录生成各分类 XLSX 与“分表”文件夹
7	查看日志	输出目录下生成 error.log，记录每一步的 INFO/WARN/ERROR

注意：处理过程中请勿关闭窗口；若勾选“遇错停止”，出错会立即中断并提示，否则继续并记录日志。

三、程序执行流程总览

核心流程由 core/pipeline.py 中的 Pipeline.run() 按顺序串联执行。解压、合并完成后，资金交易流水按 V1.9 的 8 个步骤处理；步骤 1.5 仍仅用于新版“逐卡”格式适配，旧版为无操作。

环节	名称	进度区间	对应模块
0	运行前准备（建目录/日志/临时目录）	—	pipeline
1	解压 ZIP 文件	0% – 10%	extractor
1.5	新版逐卡格式适配（仅新版）	5% – 10%	format_adapter
2	合并同类 CSV	10% – 20%	merger
3	清空白并全字段去重	20% - 30%	cleaner + deduper
4	删除交易时间和交易金额双空行	30% - 36%	cleaner
5	补卡号/账号、户名/证件号码	36% - 48%	completer
6-7	金额数值化、收付标志标准化	48% - 60%	cleaner
8	六字段最终去重	62% - 72%	deduper
最终输出	汇总 XLSX + 超限分片 + 分表	72% - 100%	converter + splitter

流程文字版：解压 → （新版：逐卡适配）→ 合并（按 7 种 CSV 类型）→ 清空前后空白 → 全字段去重 → 删除时间和金额双空行 → 补卡号/账号 → 补户名/证件号码 → 金额数值化 → 收付标志标准化 → 六字段最终去重 → 最终输出（汇总 XLSX + 按户名分表）。

四、程序执行步骤详解（核心）

| 步骤 0：运行前准备

【目的】创建输出目录、初始化日志、创建临时工作目录，为后续步骤提供统一工作空间。

【输入】用户选择的 ZIP 文件列表、输出目录、保留中间文件开关、遇错停止开关。

【处理】os.makedirs 创建输出目录；在输出目录下创建 error.log；tempfile.mkdtemp 创建临时目录（前缀 fund_clean_）。

【输出】输出目录（含 error.log）、临时目录 fund_clean_xxx。

【关键实现要点】

- 日志写入输出目录方便查看（error.log）。
- 临时目录用于存放解压后的中间 CSV，默认完成后删除。

【性能与可优化点】

- 日志可归档或按日期轮转。
- 临时目录命名可加时间戳，避免残留冲突。

| 步骤 1：解压 ZIP 文件

【目的】把用户选择的案件 ZIP 解压，并从内部银行 ZIP 文件名解析出银行名与 CSV 类型，按类型归类所有 CSV。

【输入】用户选择的案件 ZIP（顶层 ZIP，内含多个银行 ZIP 与“任务信息”csv）。

【处理】①第一层：解压用户 ZIP 到案件目录。②对每个成员文件：若为 .zip（银行 ZIP），用 parse_bank_zip_name 剥离类型关键词得到（银行名, CSV 类型），解压后收集其中的 CSV（通常仅 1 个）到对应类型；若为 .csv（任务信息），用 get_output_category 归类，来源记“全局”。

【输出】按类型组织的字典 {CSV 类型: [(银行名, CSV 路径), ...]，...}，共 7 种类型。

【关键实现要点】

- 银行名 = ZIP 文件名去掉 CSV 类型关键词。
- 类型关键词按“长优先”匹配，避免“账户信息”误吃“关联子账户信息”。
- 支持数字后缀（如“交易明细信息 3.zip”）。
- 安全解压：过滤 ../ 绝对路径成员，防路径穿越。

【性能与可优化点】

- 解压中转文件可按类型分流，减少中间 I/O。
- 解析失败的类型可单独归组并记录，避免静默丢弃。

| 步骤 1.5：新版“逐卡”格式适配（仅新版）

【目的】识别“逐卡”新版反馈包（交易明细文件名带卡号），并用文件名卡号补全为空的“交易卡号”，保证下游按键正确。

【输入】extract_all 输出的归类结果 dict、新版逐卡明细 CSV（文件名形如 {银行}交易明细信息({卡号}).csv）。

【处理】①先用 is_new_format 检测顶层 ZIP 是否存在“交易明细信息(卡号).zip”；②若为新版，遍历“交易明细信息”分类下每个逐卡 CSV，用 parse_bank_zip_name_v2 从文件名解析括号内卡号（剥离 _001/_000000 批量后缀，“-”视为无卡号）；③用 normalize_detail_card_cols 仅把该 CSV 中为空的“交易卡号”补上。仅补空、不覆盖非空，且不误填“交易账号”。

【输出】补全交易卡号后的逐卡明细 CSV（写回原路径），返回补全单元格数。

【关键实现要点】

- 文件名卡号即“交易卡号”，故只补交易卡号，避免用卡号误填不同的交易账号。
- 对于括号内为“-”或为空（如“中国光大银行股份有限公司交易明细信息(-).zip”）视为无卡号，不做改动。
- 新版/旧版自动识别，旧版包此步骤为无操作，走 V1.6 原逻辑。

【性能与可优化点】

- 若后续需要按文件名卡号同时校验/补“交易账号”，可扩展映射，但需以账户表关系为准。
- 可统计其补全行数，便于观察数据完整度。

| 步骤 2：合并同类 CSV

【目的】把同一类型、来自不同银行的 CSV 流式合并为单个文件，新增“银行来源”列标注来源。

【输入】步骤 1（或 1.5 适配后）输出的按类型分组结果。

【处理】①对每个类型：先扫描所有文件表头，取列并集作为完整列集合，并将“银行来源”置于首列；②流式逐文件读取，写入“银行来源 = 银行名”，按完整列集合重排（缺失列补空），追加写入；第一个文件写表头，后续追加数据。

【输出】每类型一个合并 CSV（UTF-8-SIG 编码），文件名如“交易明细信息_合并.csv”。

【关键实现要点】

- 流式写入避免在内存中构建完整 DataFrame，防止大表内存溢出（260 万行场景）。
- 列并集保证任何银行的列都不丢失。
- “银行来源”列用于后续分表区分不同银行。

【性能与可优化点】

- 表头扫描与数据读取各走一遍读盘，可缓存列并集减少重复扫描。
- 写入建议设置 quoting，避免含逗号字段被误切分。

| 步骤 3：清空前后空白并全字段去重

【目的】统一资金流水字段格式，并删除所有字段完全相同的重复记录，降低后续处理量。

【输入】步骤 2 输出的全部合并 CSV。

【处理】资金交易流水先清理所有字段前后空白；随后以所有字段同时相同为重复条件执行全表去重，保留首次出现的一行。其他类型表仍按原有全列去重逻辑处理。

【输出】全字段去重后的资金流水 CSV（写回原路径）。

【关键实现要点】

- 首轮去重是全部字段去重，不是 V1.8 的六字段去重。
- keep='first' 保留首次出现记录；账户信息表逻辑保持不变。

【性能与可优化点】

- 可统计并记录每个文件去重行数。
- 首轮全字段去重与最终六字段去重分两阶段执行，符合 V1.9 规定顺序。

| 步骤 4：删除交易时间和交易金额同时为空的行

【目的】删除既无交易时间又无交易金额的无效流水，同时保留有金额但时间缺失的记录。

【输入】第 1-2 步完成后的资金交易流水 CSV。

【处理】仅当“交易时间”和“交易金额”两个字段同时为空时删除该行。交易时间为空但交易金额有值，或交易金额为空但交易时间有值，均保留。

【输出】清洗后的交易明细 CSV（写回原路径）。

【关键实现要点】

- 空值判定覆盖 None、空字符串、'nan'。
- 不再使用“交易时间为空即删除”的旧规则。

【性能与可优化点】

- 清洗规则可抽取为可配置策略，便于按业务调整。
- 该步骤只处理文件名含“交易明细”的资金流水表。

| 步骤 5：补全账户键、户名和证件号码

【目的】按账户信息表的卡号与账号对应关系补齐资金流水空白字段。

【输入】第 3 步清洗后的资金流水 CSV、账户信息 CSV。

【处理】①交易卡号为空时，用交易账号查账户表并补卡号；交易账号为空时，用交易卡号查账户表并补账号；查不到则留空。②随后用卡号优先、账号其次查账户表，补全空白的交易户名和交易证件号码。查表采用 VLOOKUP 的首个匹配语义，仅补空白单元格，不覆盖原值。

【输出】已补全账户键、户名和证件号码的资金流水 CSV（写回原路径）。

【关键实现要点】

- 严格先补交易卡号和交易账号，再补交易户名和交易证件号码。
- 账户表重复键取首个匹配项，未找到对应关系时保持空白。

【性能与可优化点】

- 仅处理资金交易流水；账户信息表及其他表内容不变。
- 可输出补全匹配率和未匹配样本，便于评估账户表质量。

| 步骤 6-7：金额数值化和收付标志标准化

【目的】统一交易金额、交易余额的数值格式与收付方向内容，便于 Excel 分析。

【输入】第 4-5 步补全后的资金流水 CSV。

【处理】①交易金额、交易余额转换为数值并保留两位小数，XLSX 单元格设置 0.00 显示格式。②收付标志中“借”“1”“D”“d”“转出”统一替换为“出”；“贷”“2”“C”“c”“入”“转入”统一替换为“进”；其他内容保持原样。

【输出】金额和收付标志标准化后的资金流水 CSV（写回原路径）。

金额数值化后再执行收付标志替换，严格遵循 V1.9 步骤顺序。

【关键实现要点】

- 收付标志采用精确值匹配，不进行模糊替换。
- 无法转换为数值的非空内容保留原值，避免数据丢失。

【性能与可优化点】

- 金额转数值和收付标志替换在同一次 CSV 读取中完成，减少大表 I/O。
- 可在日志中记录无法数值化的非空金额数量及示例。
- 收付标志映射集中在配置中维护，便于后续扩展银行规则。

| 步骤 8：六字段最终去重

【目的】在补全和标准化后复核重复流水，保留首行。

【输入】第 6-7 步完成金额和收付标志标准化后的资金流水 CSV。

【处理】仅对资金交易流水按“交易卡号、交易时间、交易金额、交易余额、收付标志、交易对手账卡号”六列同时重复为条件去重；其他表仍按原逻辑处理。

【输出】第 8 步最终去重后的资金流水 CSV（写回原路径）。

【关键实现要点】

- 最终去重位于补全、金额数值化和收付标志标准化之后。
- 余额不同即视为不同流水，六列全部相同才删除。

【性能与可优化点】

- 六列键集中在 utils/config.py 的 DEDUP_COLS_DETAIL。
- 可统计最终去重删除行数并写入日志。

| 最终输出：汇总 XLSX、超限分片与分表

【目的】把各类型合并 CSV 转成 XLSX；资金流水额外输出汇总表并按 银行+户名+账号 拆分分表。

【输入】全部合并 CSV、输出目录。

【处理】①非交易明细表：按原有逻辑直接 CSV→XLSX。②交易明细表：输出汇总 XLSX，超过 1,048,576 行自动分片，每片包含相同表头。③分表继续按银行、户名、账号流式分组；汇总表和分表中的金额均为数值，并显示两位小数。

【输出】输出目录：各分类 XLSX；交易明细汇总 XLSX（超限自动分片）；子目录“分表/”下的 {户名}_{银行}_{卡号}.xlsx；以及 error.log。

【关键实现要点】

- 长数字列（列名含“卡号/账号/证件号码/身份证/手机/电话”）在 XLSX 中强制文本格式，防科学计数法。
- 交易金额、交易余额为数值类型，并设置 0.00 显示格式；汇总表超限自动分片。
- 分表流式分块 + 向量化分组键，避免 300 万+ 行 OOM。
- 写入前用 ILLEGAL_XML_CHARS_RE 清除非法控制字符，防止 IllegalCharacterError；V1.7 用 is_string_dtype 兼容 pandas 3.x。

【性能与可优化点】

- 分表数量过多时可考虑合并小分组或按银行归档到子目录。
- 写 XLSX 逐 sheet 追加，可评估 openpyxl 写缓存参数。
- 汇总表与分表可复用同一次格式化的 DataFrame。

| 步骤 收尾：清理临时文件 / 关闭日志

【目的】处理完成后清理临时工作目录，关闭日志文件，统计耗时并反馈界面。

【输入】临时目录、日志对象、是否保留中间文件开关。

【处理】若未勾选“保留中间文件”，则 shutil.rmtree 删除临时目录；关闭 ErrorLogger；记录总耗时。

【输出】（无遗留中间文件）界面返回“处理完成”，进度 100%。

【关键实现要点】

- 保留中间文件开关可开关：用于调试时保留各步骤 CSV。
- 异常路径会写入错误堆栈到 error.log，并依据“遇错停止”决定是否中断。

【性能与可优化点】

- 中间文件保留后可在日志中列出其路径。
- 异常时建议保留现场（部分中间文件）以便复现。

五、数据格式与关键约定

以下为真实数据格式的关键发现，直接影响各步骤的处理逻辑。V1.7 新增识别“逐卡”新版格式。

5.1 ZIP 结构（老版 / 新版）

- 老版（V1.6 兼容）：顶层 ZIP 内含多个“{银行名}{CSV 类型}.zip”（如“莱商银行股份有限公司交易明细信息.zip”），每个银行 ZIP 仅 1 个 CSV，文件名与 ZIP 名一致。
- 新版（V1.7 适配）：交易明细升级为“逐卡”，文件名为“{银行名}交易明细信息({卡号}).zip”（如“中国农业银行交易明细信息(6228411333029998167).zip”），一个 ZIP 对应一张卡，卡号写在文件名括号内，可能带批量后缀 _001/_000000，个别为“(-)”。
- 顶层另有“任务信息(成功).csv”和“任务信息(失败).csv”。
- 银行名从 ZIP 文件名剥离类型关键词获得（parse_bank_zip_name / _v2）。

5.2 CSV 格式

- 编码：全部 GBK/GB18030（chardet 对短中文文本置信度仅 0.14–0.19，需强制信任）。
- 分隔符：逗号 ,（字段用双引号包裹）。
- 特殊格式：每个字段值尾部含 \t（如“交易卡号\t”）。
- csv.Sniffer 陷阱：尾部 \t 会误导 Sniffer 将分隔符检测为制表符，需二次验证。

5.3 CSV 类型（7 种）

共有优先权信息、关联子账户信息、强制措施信息、任务信息(成功)、任务信息(失败)、交易明细信息、人员信息、账户信息。

5.4 关键列名差异

预期	实际
去重列“收费标志”	“收付标志”
账户表“交易户名”	“账户开户名称”
账户表“交易证件号码”	“开户人证件号码”

因此 completer 等模块使用多关键词模糊匹配列名（_find_any_column），兼容不同银行命名差异。

六、关键技术与已解决问题

问题	解决方案
新版“逐卡”文件识别（V1.7）	is_new_format 检测“交易明细信息(卡号).zip”；parse_bank_zip_name_v2 解析卡号并剥离批量后缀
资金流水处理规则调整（V1.9）	**先清空前后空白并按全字段去重；补全与标准化完成后，再按交易卡号、交易时间、交易金额、交易余额、收付标志、交易对手账卡号六列去重。**
逐卡明细卡号缺失（V1.7）	format_adapter 用文件名卡号补全为空的“交易卡号”，仅补空、不覆盖非空
pandas>=3.0 分表控制字符清理失效（V1.7）	splitter 用 is_string_dtype 替代 dtype==object，兼容 dtype=str 返回 string 类型
CSV 读取失败（EOF inside string）	read_csv_auto 增加 GBK 最优先 + C/Python 引擎回退 + 多编码兜底
分隔符误检为 tab	尾部 \t 误导 Sniffer → 引号外逗号计数二次验证
补全失败（0 行）	账户表列名不匹配 → _find_any_column() 多关键词模糊匹配
encoding 置信度低	中文 GB18030 置信度仅 0.14 → 直接信任、不设阈值
长数字科学计数法	列名含“卡号/账号/证件号码/身份证/手机/电话”→XLSX 强制文本格式
Excel 非法控制字符（\x1c / \x10）	写入前用 ILLEGAL_XML_CHARS_RE 去除
大数据量内存溢出	合并/分表均流式处理；分表分块 10 万行 + 向量化分组键

七、实际测试结果示例

输入：1 个案件 ZIP（约 7.9MB），内含 63 个银行 ZIP，涵盖 18 家银行。

输出表	行数	列数
交易明细信息	144,990	32
人员信息	58	23
账户信息	62	44
关联子账户信息	49	10
任务信息(成功)	59	12
任务信息(失败)	2	12
强制措施信息	5	9
分表	56 个文件	—
补全率	93.6%	—

另：*V1.7* 已用“逐卡”新版反馈包（含 *768* 个逐卡明细文件）完整跑通，补全填充 *1,376,383* 行、明细汇总 *1,469,562* 行、生成 *1,119* 个分表。

八、基于执行步骤的优化建议

环节	现状	优化建议
解压	中转文件写盘	按类型直接分流，减少中间读盘 I/O；未识别类型单独归组并记录
新版适配	仅补空“交易卡号”	如需同时补“交易账号”，应以账户表卡号↔账号关系为准，勿直接用文件名卡号
合并	表头扫描与数据各读一遍	缓存列并集结构；写入设置 quoting 防含逗号字段误切分
去重规则分阶段	**首轮全字段去重，最终六字段去重**	**持续统计各轮删除行数；保持两轮顺序，便于核验标准化前后的重复变化**
清洗	规则写死在代码	抽取为可配置策略，便于按业务调整并统计删除行数
补全	映射构建用逐行 iterrows	账户表极大时改为向量化 join；输出匹配率与未匹配样本
清理卡号	converter/completer 逻辑重复	统一为幂等清理函数，保证语义一致；校验卡号长度/格式
分表	临时 CSV 中转 + 分组	小分组合并；按银行归档子目录；与汇总复用同一格式化结果
日志	单一 error.log	按日期轮转；保留中间文件时列出路径便于复现

—— 《 完 》 ——